DIPLOMATURA EN CIENCIA DE DATOS Y ANÁLISIS AVANZADO

Centro de e-Learning UTN BA · Proyecto Final Integrador

Precio esperado y detección de desvíos en publicaciones de Airbnb de la Ciudad Autónoma de Buenos Aires

Informe Final

Grupo 27

Integrantes: Ximena Romero y Carlos Siboni

Fecha: 26 de octubre de 2026

Repositorio: github.com/CSIB-P/TP_final_999201523_Siboni_Romero

1. Resumen ejecutivo

En la Ciudad Autónoma de Buenos Aires conviven casi treinta mil publicaciones de Airbnb y cada anfitrión fija su precio comparando informalmente con lo que ve alrededor, sin controlar por capacidad, dormitorios, baños ni equipamiento. Este proyecto estima el precio de consenso del mercado para un conjunto de atributos, mide la brecha entre ese precio esperado y el que cada anfitrión publica, e identifica las publicaciones cuyo posicionamiento se aparta de forma significativa.

La solución es un modelo de regresión sobre el logaritmo del precio por noche, entrenado con datos públicos de Inside Airbnb. Se compararon siete alternativas y el modelo elegido es XGBoost, que sobre un conjunto de prueba reservado y nunca visto alcanza un error porcentual mediano de 21,5%, frente a 28,3% del benchmark de negocio, que es el precio mediano del barrio para el mismo tipo de alojamiento. La mejora es de 6,8 puntos porcentuales (24,1% en términos relativos) y es estadísticamente significativa en la validación cruzada agrupada ($p < 0,001$).

Aplicando el umbral fijado antes de conocer los resultados, el 20,5% de las publicaciones evaluadas presenta un desvío relevante: 11,3% cobra bastante por debajo de lo que logran propiedades comparables y 9,2% bastante por encima. El resultado se comunica publicación por publicación: esta unidad está un 43% por debajo, o un 85% por encima, del precio esperado para propiedades comparables. El trabajo muestra además una asociación entre posicionamiento y actividad reciente, decreciente a partir del segundo decil de brecha y con una excepción en el más subvaluado, que el informe documenta junto con sus límites: es asociativa y no causal.

Principales resultados

Métrica sobre el conjunto de prueba	Benchmark	Reg. lineal	XGBoost
Error porcentual mediano (MdAPE)	28,3%	24,5%	21,5%
Error porcentual medio (MAPE)	36,3%	34,5%	30,4%
Error absoluto medio (ARS)	55.001	46.104	42.123
R^2 sobre log(precio)	0,20	0,43	0,51

2. Definición del problema y relevancia

Contexto y motivación. El alquiler temporario es una actividad económica relevante en CABA y el precio es la decisión que más determina el ingreso de un anfitrión. La referencia disponible, sin embargo, es pobre: el sitio solo permite mirar lo que cobran unidades cercanas, sin ajustar por capacidad ni equipamiento, de modo que un monoambiente y un cuatro ambientes de la misma cuadra aparecen como comparables.

Objetivo medible. Estimar el precio por noche esperado de cada publicación con un error significativamente menor que el del benchmark de mediana por barrio y tipo de alojamiento, y que el de una regresión lineal. Sobre esa estimación, identificar las publicaciones cuya brecha supera un umbral definido de antemano y analizar su relación con la actividad reciente.

Audiencia. Dueños particulares e inversores de alquiler temporario de CABA, que son quienes toman la decisión de precio.

Hipótesis de trabajo. Hipótesis de trabajo. Las características de la unidad explican una parte de la variación del precio sustancialmente mayor que el barrio y el tipo de alojamiento. La evidencia la respalda: el benchmark por barrio y tipo explica apenas el 20% de la varianza del logaritmo del precio en el conjunto de prueba (14% en validación cruzada), mientras que el modelo completo llega al 51% (51% en validación cruzada), y el análisis de importancia de variables ubica a la capacidad, la escala del anfitrión y los dormitorios como las variables más influyentes; la ubicación, sumando latitud, longitud y barrio, pesa 21,3%, menos que capacidad, dormitorios y baños juntos (37,2%).

Importancia estratégica. Para un anfitrión, el precio es la única palanca que controla por completo; para una administradora, la estimación permite revisar una cartera entera en minutos; y para el mercado, documentar la dispersión de precios entre unidades equivalentes aporta a una discusión pública que hoy se apoya en percepciones.

3. Datos y metodología

3.1 Metodología: CRISP-DM

El proyecto siguió las fases de CRISP-DM y el notebook del repositorio está organizado con esa misma estructura, de modo que cada decisión queda trazable. La comprensión del negocio fijó el KPI, el benchmark y el criterio de éxito antes de tocar los datos; la de los datos produjo el diccionario, el mapa de nulos y el diagnóstico de concentración; la preparación definió el universo y las variables derivadas; el modelado buscó hiperparámetros y comparó alternativas con validación cruzada agrupada; y la evaluación se hizo una sola vez sobre datos reservados. El despliegue no se aborda: como se argumenta más adelante, el modelo todavía no está en condiciones de usarse sin supervisión.

Las decisiones quedaron registradas en el archivo data_log.md del repositorio, con treinta entradas que indican motivo y evidencia. Las marcadas como ex ante se fijaron en la pre-entrega y no se modificaron después de ver resultados.

3.2 Fuente y volumen

Se utilizó Inside Airbnb, un proyecto que publica datos extraídos del sitio de Airbnb bajo licencia Creative Commons Attribution 4.0. El archivo detallado del snapshot relevado entre el 25 y el 27 de septiembre de 2026 contiene 29.753 publicaciones de CABA con 90 variables, y se complementa con el archivo de reseñas, que aporta 1.241.902 registros con fecha.

La pre-entrega usó el snapshot del 29 de junio de 2026; al retomar el proyecto el vigente era el de septiembre y se optó por el más reciente, por lo que las cifras no coinciden exactamente con las de la pre-entrega aunque las conclusiones se sostienen. La variable de dormitorios pasó de 17,5% de nulos en junio a 0,04% en septiembre.

3.3 Calidad de los datos y conclusiones del análisis exploratorio

Diccionario de las diez variables principales

Variable	Tipo	Descripción	Nulos
price	Numérica	Precio por noche en ARS	7,1%
neighbourhood_cleansed	Categórica	Barrio oficial (47 con oferta)	0%
room_type	Categórica	Tipo de alojamiento (4 valores)	0%
accommodates	Numérica	Capacidad de huéspedes (1 a 16)	0%
bedrooms	Numérica	Cantidad de dormitorios	0,04%
bathrooms_text	Texto	Baños y si son compartidos	0,07%
amenities	Texto	Equipamiento; se usa su cantidad	0%
minimum_nights	Numérica	Estadía mínima en noches	0%
calculated_host_listings_count	Numérica	Publicaciones del anfitrión	0%
number_of_reviews_ltm	Numérica	Reseñas de los últimos 12 meses	0%

Del análisis exploratorio surgieron cuatro conclusiones que condicionaron todo lo que vino después. La primera es que el precio está íntegramente en pesos argentinos, con distribución unimodal en escala logarítmica y mediana de 106.393 ARS: no hay mezcla de monedas, algo que no podía darse por sentado en un mercado con inflación. La segunda es que presenta valores extremos, con un máximo declarado superior a 160 millones por noche, por lo que se recortó el universo entre los percentiles 0,5 y 99,5, delimitando la población entre 22.123 y 1.596.087 ARS.

La tercera es que los nulos de las variables de reseñas comparten la misma proporción, 11,69%, consistente con publicaciones sin reseñas todavía; la variable de licencia tiene 98,28% de nulos y no se usa como variable del modelo. La cuarta, y la más determinante, es que la oferta está muy concentrada: el 63,6% de las publicaciones pertenece a anfitriones con más de una (apenas el 26,0% de los anfitriones), y el 31,3% tiene al menos una gemela del mismo anfitrión con idéntico

barrio, tipo, capacidad, dormitorios y baños, con precios que difieren en una mediana de 9,9%. Ese hallazgo obliga al esquema de validación de la sección siguiente.

3.4 Preparación y universo de análisis

Del archivo completo se excluyeron las publicaciones sin precio, las de precio cero y las que exigen más de noventa noches de estadía mínima, que corresponden a arreglos de larga estadía y no a alquiler temporario. Ese último filtro afecta solo 71 publicaciones, de modo que es conceptual más que material. Tras el recorte de extremos, el universo final queda en 27.287 publicaciones de 13.432 anfitriones. Los percentiles se calcularon sobre toda la base antes de la partición y el recorte es un filtro sobre la variable objetivo, por lo que los errores reportados corresponden a la población sin precios extremos.

Se derivaron tres variables: la cantidad de baños y su carácter compartido, desde el texto libre, y la cantidad de elementos de equipamiento, desde la lista JSON. Los faltantes numéricos se imputaron con la mediana más un indicador de ausencia. Se excluyó la disponibilidad anual de las variables de entrada, porque refleja en parte la ocupación, que se analiza en la segunda etapa.

4. Modelado y evaluación

4.1 Esquema de validación

Se apartó un conjunto de prueba con el 20% de los anfitriones, equivalente a 5.721 publicaciones de 2.687 anfitriones, y no se lo tocó hasta la evaluación final. La partición se hizo agrupando por anfitrión y no al azar: con publicaciones casi idénticas del mismo dueño, una partición aleatoria deja copias de la misma unidad a ambos lados y el modelo termina evaluándose sobre lo que ya vio.

El efecto se midió con un control. Si la diferencia entre ambos esquemas fuera casualidad, debería aparecer en todos los modelos por igual. La regresión lineal, que no puede memorizar publicaciones individuales, mejora apenas 0,30 puntos porcentuales al pasar a partición aleatoria, mientras que Random Forest mejora 1,80 y XGBoost 1,79. El efecto es mínimo en la regresión lineal y mayor en los modelos que pueden memorizar publicaciones individuales, con un efecto intermedio en el benchmark y en KNN (Figura 1): es consistente con la fuga entre publicaciones gemelas y la respalda como evidencia indirecta.

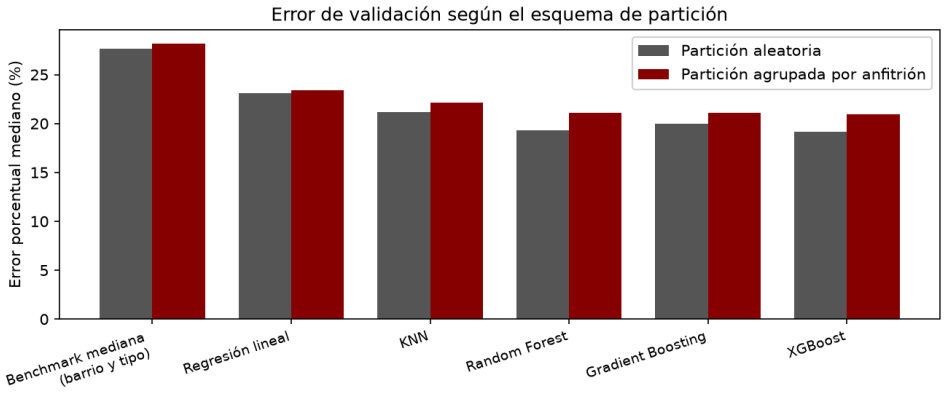


Figura 1. Error de validación según el esquema de partición. Los modelos que pueden memorizar publicaciones individuales son los que más se benefician de la partición aleatoria. Elaboración propia.

4.2 Algoritmos probados y criterio de selección

Se compararon siete alternativas: dos benchmarks de grupo (mediana y promedio por barrio y tipo), una regresión lineal, K vecinos más cercanos, Random Forest, Gradient Boosting por histogramas y XGBoost. Los hiperparámetros se buscaron con validación cruzada agrupada de tres folds sobre el conjunto de desarrollo, y la comparación final se hizo con validación cruzada agrupada de cinco folds por cuatro repeticiones.

El criterio de éxito se fijó en la pre-entrega, antes de ver cualquier resultado: el modelo final debe superar al benchmark de negocio y a la regresión lineal, ambos con diferencia estadísticamente significativa. La significancia se evaluó con un test t pareado unilateral sobre los veinte folds, con la corrección de Nadeau y Bengio, que compensa el hecho de que los folds comparten datos de entrenamiento y por lo tanto no son observaciones independientes. Al ser un criterio comparativo y no un umbral numérico, no puede calibrarse mirando los resultados.

Métrica elegida y por qué. Los modelos se entrenan sobre log(precio) y se comparan con el error porcentual absoluto mediano (MdAPE), calculado en pesos. Se eligió porque (1) el precio tiene colas muy largas y la mediana no se deja arrastrar por unos pocos errores enormes, a diferencia del RMSE y del MAE; (2) un error en porcentaje es comparable entre una habitación barata y un departamento caro, mientras que un error en pesos castiga casi solo a las unidades caras; y (3) está en la misma escala en que se comunica el resultado («X% por encima o por debajo del precio esperado»). Se reportan además MAPE, MAE y R^2 sobre log(precio) como complemento.

Comparación de modelos (validación cruzada agrupada, 5 folds × 4 repeticiones)

Modelo	MdAPE	Desvío	R^2 log	Supera benchmark y lineal
Benchmark mediana	28,17%	0,68	0,14	referencia
Benchmark promedio	39,14%	1,13	0,04	no

Modelo	MdAPE	Desvío	R^2 log	Supera benchmark y lineal
Regresión lineal	23,44%	0,87	0,42	referencia
KNN	22,12%	0,56	0,46	sí (p = 0,004)
Random Forest	21,08%	0,68	0,52	sí (p < 0,001)
Gradient Boosting	21,06%	0,71	0,52	sí (p < 0,001)
XGBoost	20,98%	0,69	0,51	sí (p < 0,001)

Los cuatro modelos no lineales cumplen el criterio. XGBoost obtiene el menor error, pero conviene ser explícito sobre la fuerza de esa ventaja: frente a Gradient Boosting la diferencia es de 0,08 puntos porcentuales con un valor p de 0,63, y frente a Random Forest de 0,10 puntos con p de 0,68. Es decir, los tres modelos de árboles están estadísticamente empatados. XGBoost queda seleccionado por tener el menor error medio entre los tres (20,98% contra 21,06% y 21,08%) y el menor desvío entre ellos (0,62 contra 0,71 y 0,68; KNN tiene 0,56, pero un error 1,2 puntos mayor), no porque exista evidencia estadística de que sea superior. El criterio fijado de antemano no definía un desempate entre modelos que lo cumplen, y la elección no altera ninguna conclusión del informe.

4.3 Evaluación sobre el conjunto de prueba

La evaluación se realizó una sola vez, al final, sobre los 5.721 registros reservados. XGBoost alcanza un error porcentual mediano de 21,51%, contra 28,34% del benchmark y 24,45% de la regresión lineal, lo que representa una reducción de 24,1% respecto de la referencia de negocio. El error medido en validación cruzada fue de 20,98%, de modo que la diferencia al pasar a datos nunca vistos es de 0,87 puntos, esperable para una única partición de 5.721 publicaciones. Las comparaciones estadísticas se hicieron en validación cruzada; en el conjunto de prueba se reportan estimaciones puntuales.

4.4 Qué explica el precio esperado

El análisis de importancia de variables con valores SHAP, calculado sobre el conjunto de prueba y agrupando las columnas por variable original, confirma la hipótesis de trabajo. La capacidad de huéspedes explica el 14,1% de la contribución total, la cantidad de publicaciones del anfitrión el 13,5%, los dormitorios el 12,7% y los baños el 9,9%. En conjunto, capacidad, dormitorios y baños (37,2%) superan a la ubicación, que entre latitud, longitud y barrio suma el 21,3%; como esas variables están correlacionadas y se reparten el crédito, su orden relativo debe leerse con cautela.

El segundo lugar de la escala del anfitrión es un resultado no anticipado: quienes tienen muchas publicaciones fijan precios sistemáticamente distintos de los ocasionales, algo coherente con una

gestión más profesionalizada. Estos valores explican el comportamiento del modelo y no establecen relaciones causales.

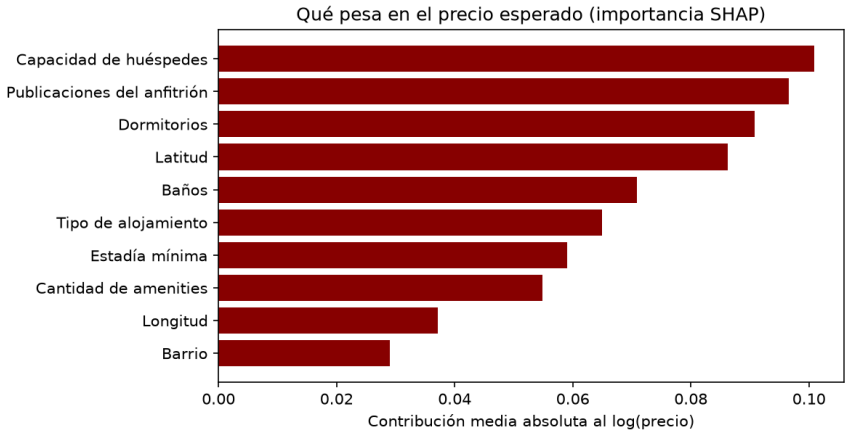


Figura 2. Importancia global de las variables, medida con valores SHAP sobre el conjunto de prueba. Elaboración propia.

5. Impacto en el negocio

5.1 El resultado traducido al lenguaje del anfitrión

La brecha se define como el cociente entre el precio publicado y el esperado, expresado en escala logarítmica para que cobrar la mitad y cobrar el doble queden a igual distancia del cero, y se comunica en porcentaje. Una publicación queda señalada cuando su desvío supera el doble del error típico del modelo, umbral que se fijó en la pre-entrega en 0,4253 en escala logarítmica, equivalente a cobrar más de 53,0% por encima o más de 34,6% por debajo del precio esperado. Ese umbral no se recalculó con el modelo final, para que la definición de desvío no dependiera del modelo elegido.

La razón de exigir el doble del error es que el modelo se equivoca con una mediana de 23,6% hacia arriba y 19,1% hacia abajo (en escala logarítmica, ln 1,239 = 0,214; el doble, 0,428, está muy cerca del umbral de 0,4253). Señalar desvíos menores a esa magnitud sería reportar ruido: con un umbral del 20%, más de la mitad del mercado quedaría marcada.

Ejemplos representativos de publicaciones señaladas

Barrio	Tipo	Capacidad	Precio	Esperado	Brecha
Palermo	Unidad completa	2	50.451	89.144	−43,4%
Puerto Madero	Unidad completa	2	128.994	228.379	−43,5%
Recoleta	Unidad completa	3	229.322	123.764	+85,3%
Palermo	Unidad completa	2	161.618	87.212	+85,3%

Aplicando ese criterio, el 20,5% de las publicaciones del conjunto de prueba presenta un desvío relevante, repartido entre 11,3% por debajo y 9,2% por encima. El indicador varía de forma apreciable entre barrios, de 12,0% en Monserrat a 29,1% en Villa Crespo, y esa comparación entre segmentos es su uso más informativo. El nivel absoluto depende en parte de la dispersión de los residuos del modelo, de modo que las publicaciones señaladas deben entenderse como candidatas a revisión y no como errores de precio comprobados.

5.2 Magnitud de la brecha

Cuantificar el beneficio exige un cuidado especial. Afirmar que corregir el precio produce un ingreso adicional supondría que bajar o subir el precio modifica la demanda, y eso es exactamente lo que estos datos no permiten sostener. Por eso el valor se expresa como un escenario paramétrico, que mide la magnitud agregada de la brecha bajo supuestos explícitos que el lector puede discutir.

Sobre las 644 publicaciones subvaluadas del conjunto de prueba, y suponiendo que el anfitrión cierre la mitad de su brecha y mantenga diez noches ocupadas por mes, la diferencia anual agregada asciende a unos 2.349 millones de pesos. Con supuestos más conservadores, treinta por ciento de la brecha y cinco noches por mes, baja a 705 millones. Son cotas superiores, porque suponen que la ocupación no cae al subir el precio, algo que los datos no permiten afirmar. El rango completo de escenarios figura en el repositorio. No es una proyección de ingresos recuperables, sino una medida del tamaño del fenómeno sobre el 20% del mercado analizado, y no incluye los costos de implementar el servicio, que no se estimaron.

5.3 Posicionamiento y demanda: una asociación, no una causa

La segunda etapa del trabajo examina si el posicionamiento del precio se relaciona con la actividad reciente, aproximada por la cantidad de reseñas de los últimos doce meses. Se eligió esa medida porque es la única independiente de la antigüedad de la publicación: su correlación con los días transcurridos desde la primera reseña es de −0,02, frente a 0,53 del total histórico.

La asociación es clara y consistente: la correlación de Spearman entre brecha y actividad es de −0,145 con p inferior a 0,0001, y la mediana de reseñas desciende de once en el segundo decil a una sola en el decil más caro. El resultado se sostiene al excluir las publicaciones sin reseñas y las de menos de un año, y al medir la actividad en ventanas de noventa y ciento ochenta días sobre el archivo de reseñas, donde la correlación se mantiene entre −0,149 y −0,155. El decil más subvaluado no sigue el patrón: su mediana (5 reseñas) es menor que la de los deciles 2 a 7, de

modo que la relación es decreciente desde el decil 2 pero no monótona en todo el rango; no se analizó la composición de ese decil.

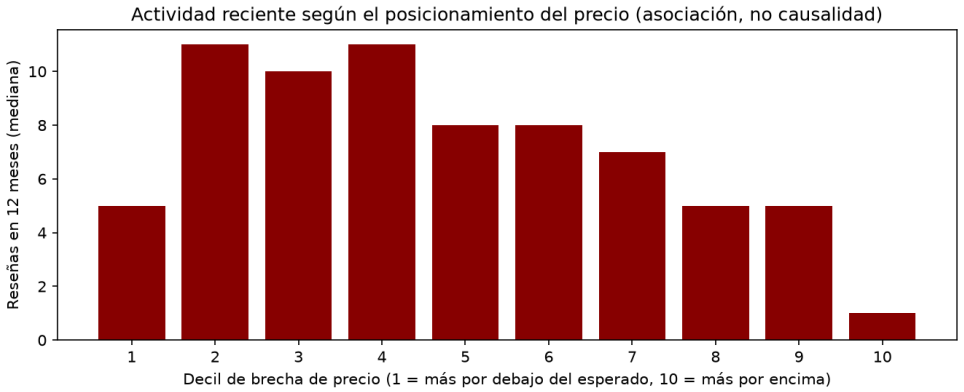


Figura 3. Actividad reciente según el posicionamiento del precio. La relación es asociativa: no permite concluir que un precio elevado cause menor demanda. Elaboración propia.

Ahora bien, de esto no se sigue que cobrar por encima del precio esperado cause menor demanda. Hay al menos tres explicaciones alternativas que los datos no permiten descartar. La primera es la calidad no observada: una unidad con problemas que el dataset no registra puede ser barata y poco solicitada a la vez. La segunda es la causalidad inversa: un anfitrión que no consigue reservas puede haber bajado el precio precisamente por eso, y al tratarse de un corte transversal no hay forma de saber qué vino primero. La tercera es el desfase temporal: el precio corresponde a septiembre de 2026 mientras que las reseñas reflejan estadías de los doce meses previos, con precios que pudieron ser otros.

Para acotar la primera explicación se repitió el análisis dentro de estratos de calificación. La asociación se mantiene e incluso se refuerza entre las publicaciones de calificación baja y media, con correlaciones de −0,176 y −0,191, lo que indica que no se explica únicamente por calidad observable. Pero entre las mejor calificadas, de 4,95 a 5,00, la asociación desaparece: la correlación cae a −0,027 y deja de ser significativa. En ese segmento no se puede interpretar la ausencia de asociación como menor sensibilidad de la demanda: el rango de calificación es muy estrecho y puede incluir publicaciones con muy pocas reseñas, para las que un 5,00 dice poco. Estos análisis por estrato son exploratorios y no se corrigen por comparaciones múltiples.

5.4 Consideraciones éticas y de privacidad

El trabajo utiliza datos sobre personas identificables, obtenidos por Inside Airbnb mediante extracción automatizada del sitio y no por entrega voluntaria de los anfitriones; el conjunto incluye identificadores y nombres. La propia fuente desplaza las coordenadas hasta unos ciento cincuenta metros, lo que protege la privacidad y limita la precisión de cualquier variable geográfica fina. En

este informe no se publican identificadores ni nombres: los casos de ejemplo se presentan por atributos de la unidad.

Se auditó además cómo se reparte el señalamiento entre grupos, y el resultado marca un límite de validez importante. El modelo señala como subvaluadas al 23,1% de las habitaciones privadas y al 32,5% de las habitaciones compartidas, frente al 10,1% de las unidades completas, y clasifica como sobrevaluadas al 55,7% de las habitaciones de hotel, con una brecha mediana de +68,7%. Dado que las unidades completas representan casi el 90% de la oferta, el modelo aprende sobre todo de ellas y estima peor los segmentos minoritarios. Usar la herramienta sobre habitaciones o alojamientos hoteleros produciría señales sistemáticamente sesgadas. También se observa que los anfitriones sin distinción de superanfitrión son señalados como subvaluados con una frecuencia muy superior, 15,2% contra 5,5%.

Por último, conviene reconocer una externalidad: una herramienta que ayude a optimizar ingresos puede incrementar el atractivo de destinar vivienda al alquiler temporario. Por eso el proyecto se presenta como análisis de mercado y no como recomendación de precio automatizada: el modelo describe lo que el mercado cobra hoy, no lo que debería cobrar.

5.5 Riesgos, limitaciones y escalabilidad

El precio analizado es el publicado, no el efectivamente cobrado; las reseñas aproximan la demanda pero no registran reservas; el análisis es transversal, basado en una única fotografía del mercado; y el modelo reproduce el precio de consenso, incluidos los errores sistemáticos de los anfitriones: una unidad subvaluada lo está respecto del mercado, no de un óptimo teórico. Además, 34 publicaciones del conjunto de prueba, el 0,59%, presentan brechas superiores al 500% con precios medianos de 985.321 pesos por noche frente a 105.488 del conjunto de prueba; son candidatas a error de carga, por ejemplo un precio mensual ingresado como precio por noche, más que decisiones de precio reales.

En cuanto a la escalabilidad, el procedimiento completo corre en unos dos minutos en una computadora corriente, así que extenderlo a otras ciudades de Inside Airbnb es inmediato en lo técnico. Lo que no es automático es la validez: cada mercado tiene su estructura y el modelo debería reentrenarse y revalidarse localmente, además de actualizarse con cada snapshot trimestral, porque captura un nivel de precios que la inflación desplaza rápido.

6. Conclusiones y recomendaciones

El modelo cumple el criterio de éxito fijado de antemano: reduce el error del benchmark de negocio en 24,1% sobre datos nunca vistos y, en validación cruzada agrupada, supera al benchmark y a la regresión lineal con diferencia significativa. La hipótesis de trabajo se confirma: las características de la unidad pesan más que la ubicación a la hora de explicar el precio, lo que justifica usar un modelo en lugar de la comparación barrial que practican hoy los anfitriones.

El hallazgo metodológico más relevante es que el esquema de validación cambia lo que uno cree estar midiendo: con partición aleatoria Random Forest y XGBoost parecen entre 1,7 y 1,8 puntos porcentuales mejores de lo que son, porque evalúan sobre publicaciones gemelas que ya vieron al entrenar. El control con la regresión lineal respalda que no es casualidad

Sobre la relación entre precio y demanda, la evidencia es consistente pero asociativa. La actividad reciente disminuye a medida que el precio se ubica por encima del esperado (Spearman de −0,145), con la excepción del decil más subvaluado; el patrón se sostiene en todas las variantes de robustez probadas, y sin embargo no autoriza a concluir que el precio cause la demanda. El análisis por estratos de calificación agrega un matiz valioso: la asociación desaparece entre las publicaciones mejor valoradas.

Recomendaciones. No utilizar el modelo como recomendador automático de precios. Su uso razonable es como herramienta de revisión: ordenar una cartera por magnitud de brecha y revisar manualmente los casos señalados. Restringir su aplicación a unidades completas, que es donde la estimación es confiable, y no extenderla a habitaciones ni a alojamientos hoteleros sin un modelo específico. Reentrenar con cada snapshot trimestral. Y antes de cualquier adopción operativa, validar la relación entre precio y demanda con datos de reservas reales, que son los que permitirían pasar de una asociación a una afirmación causal.

Próximos pasos. Incorporar la disponibilidad diaria del archivo de calendario para construir una medida de ocupación más directa que las reseñas; aprovechar el texto de las reseñas para capturar atributos de calidad que hoy quedan fuera del modelo; y comparar snapshots sucesivos para medir si el modelo mantiene su desempeño a lo largo del tiempo.

7. Código y reproducibilidad

El código completo está disponible en el repositorio público indicado en la portada. Contiene el notebook ejecutado de punta a punta, un archivo de requisitos, el registro de decisiones y la carpeta de resultados con cada tabla y figura que cita este informe. El archivo README explica

cómo ejecutarlo tanto en Google Colab como de forma local, y la carpeta de datos documenta la fuente, la licencia y la descarga.

Los datos no se versionan, por tamaño y porque la licencia exige atribución a la fuente original. Eso implica una limitación de reproducibilidad: Inside Airbnb conserva gratuitamente alrededor del último año de snapshots, de modo que el relevamiento de septiembre de 2026 dejará de estar disponible con el tiempo. Todos los procesos aleatorios usan semilla fija.

Fuentes

Inside Airbnb. (2026). Buenos Aires, Argentina, snapshot del 25 y 27 de septiembre de 2026 [Conjunto de datos]. Licencia Creative Commons Attribution 4.0. https://insideairbnb.com/get-the-data/

Nadeau, C. y Bengio, Y. (2003). Inference for the generalization error. Machine Learning, 52, 239-281. https://doi.org/10.1023/A:1024068626366

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD, 785-794. https://doi.org/10.1145/2939672.2939785

scikit-learn. Statistical comparison of models using grid search [Ejemplo de la documentación]. https://scikit-learn.org/stable/auto_examples/model_selection/plot_grid_search_stats.html

Las tres figuras y todas las tablas son de elaboración propia, generadas con matplotlib a partir del conjunto de datos citado.