DIPLOMATURA EN CIENCIA DE DATOS Y ANÁLISIS AVANZADO

Centro de e-Learning — UTN BA

PROYECTO FINAL INTEGRADOR

Precio esperado y detección de desvíos en publicaciones de Airbnb de la Ciudad Autónoma de Buenos Aires

---

Pre-entrega

Integrantes: Ximena Romero y Carlos Siboni

Fecha: 21 de septiembre de 2026

1. Resumen ejecutivo

Este proyecto analiza el mercado de alquileres temporarios de Airbnb en CABA con datos de Inside Airbnb (29.685 publicaciones, snapshot del 29 de junio de 2026). El objetivo es estimar el precio esperado según características y ubicación, detectar publicaciones con desvíos significativos y evaluar su relación con la actividad reciente de reseñas como aproximación a la demanda. Los KPI son la proporción de publicaciones con desvíos relevantes y la diferencia de actividad reciente entre los extremos de la brecha. Como evidencia preliminar, la mediana de reseñas de los últimos doce meses cae de 10 en el segundo decil a 1 en el más sobrevaluado.

2. Definición del problema y caso de negocio

Objetivo medible: estimar el precio por noche esperado con un error significativamente menor que el del benchmark de mediana por barrio y tipo y que el de una regresión lineal, detectar las que superan el umbral de brecha de la sección 4 y relacionarlas con la actividad reciente de reseñas.

Hipótesis de trabajo: las características de la unidad (capacidad, dormitorios, baños y equipamiento) explican una parte de la variación del precio sustancialmente mayor que el barrio y el tipo de habitación: el benchmark por barrio y tipo explica el 15% de la varianza de log(precio) y una regresión lineal que suma esas características, el 45%. Controlando por ellas, las publicaciones con precio por debajo del esperado muestran mayor actividad reciente de reseñas que las ubicadas por encima.

Restricciones conocidas: el precio es publicado, no necesariamente cobrado; las reseñas aproximan demanda pero no registran reservas; reflejan los 12 meses previos y los precios pudieron variar por inflación. Al tratarse de un único snapshot, el análisis es transversal. Los precios están en ARS y van de 1.216 a 171,6 millones, con mediana de 100.631.

Valor esperado: una referencia de posicionamiento del precio frente a propiedades comparables y una señal para identificar publicaciones candidatas a revisar su precio.

3. Relevamiento de fuentes de datos

Fuente: Inside Airbnb, snapshot de CABA del 29 de junio de 2026, licencia Creative Commons Attribution 4.0. Se usa el archivo detallado listings.csv.gz (29.685 publicaciones, 91 columnas), que coincide con el resumido del análisis inicial y agrega capacidad,

dormitorios, baños y equipamiento. Se dispone además de reviews.csv (1.182.517 reseñas) y del archivo de barrios: los 48 oficiales más Escollera Exterior, un polígono portuario sin publicaciones.

Diccionario de las 10 variables principales

Variable	Tipo	Descripción	Nulos
price	Numérica	Precio por noche en ARS	6,0%
neighbourhood_cleansed	Categórica	Barrio oficial (48 con oferta)	0%
room_type	Categórica	Tipo de alojamiento (4 valores)	0%
accommodates	Numérica	Capacidad de huéspedes (1 a 16)	0%
bedrooms	Numérica	Cantidad de dormitorios	17,5%
bathrooms_text	Texto	Baños y si son compartidos	0,1%
amenities	Texto	Equipamiento; se usa su cantidad	0%
minimum_nights	Numérica	Estadía mínima en noches	<0,1%
calculated_host_listings_count	Numérica	Publicaciones del anfitrión	0%
number_of_reviews_ltm	Numérica	Reseñas de los últimos 12 meses	0%

Nulos, outliers y calidad: last_review, first_review, reviews_per_month y review_scores_rating comparten 12,6% de nulos, consistente con publicaciones sin reseñas. Los nulos de bedrooms (17,5%) no son aleatorios: llegan al 50,2% en habitaciones privadas y al 14,3% en unidades completas, y se asocian con menor capacidad (78,5% admite hasta dos huéspedes, contra 47,9%) y con el doble de menciones de monoambiente o studio en el título (37,4% contra 17,0%). Es consistente con monoambientes, muy frecuentes en Buenos Aires, y con habitaciones sin el campo completo: el nulo contiene información. license tiene 98,4% de nulos y se documenta como hallazgo, no como variable.

Concentración por anfitrión: El 63,6% de las publicaciones pertenece a anfitriones con más de una; 31,7% tiene una publicación “gemela” del mismo anfitrión, con igual barrio, tipo y características, y una variación mediana de precio de 9,9%.

Decisiones de limpieza: tomadas y pendientes

Decisión	Estado
Descartar neighbourhood_group (100% nula)	Tomada
Excluir minimum_nights mayor a 90	Tomada (80 casos, 0,3%)
Recortar precio fuera de p0,5 y p99,5 (19.717 a 1.599.954)	Tomada; sensibilidad en sección 4
reviews_per_month = 0 sin reseñas; last_review queda nulo	Tomada
bedrooms: mediana más indicador de nulo	Tomada; sensibilidad pendiente
Fusión con reviews.csv en ventanas de 90 a 180 días	Pendiente (entrega final)

4. Plan de modelado y validación

Variables de entrada: capacidad, dormitorios, camas, baños y si son compartidos, cantidad de amenities, minimum_nights, calculated_host_listings_count, latitud, longitud, barrio y tipo. Se excluye availability_365 porque refleja en parte la ocupación que se analiza en la segunda etapa (con ella, la asociación entre brecha y demanda se atenúa de -0,159 a -0,134).

Partición y validación: sobre 27.533 publicaciones de 13.476 anfitriones se reserva un holdout del 20% agrupado por anfitrión (5.630 publicaciones) para la evaluación final. El desarrollo usa el 80% restante con CV agrupada por anfitrión (5 folds × 4 repeticiones). La agrupación evita fuga entre publicaciones del mismo anfitrión: con partición aleatoria, el error de Random Forest baja 3,1 pp y pasa a parecer el mejor modelo, mientras que con agrupación Gradient Boosting lo supera por 0,7 pp (p=0,039).

Métricas y benchmark: los modelos se entrenan sobre log(precio) y se evalúan en ARS mediante MdAPE, junto con MAPE y R^2 sobre log(precio). El benchmark es la mediana por barrio y tipo: el promedio se descarta por su mayor MdAPE (39,4% con recorte; 118,5% sin él), mientras la mediana alcanza 28,9% y 29,3%, respectivamente.

Baseline (desarrollo, validación agrupada de 5 folds por 4 repeticiones)

Modelo	MdAPE	Desvío	MAPE	R^2 log
Benchmark mediana	28,9%	1,0	36,4%	0,15

Regresión lineal	23,7%	0,7	31,5%	0,45

Umbral de éxito: el modelo final deberá superar al benchmark y a la regresión lineal mediante un test t pareado unilateral sobre los 20 folds, con corrección de Nadeau y Bengio (2003). Como evidencia preliminar, Gradient Boosting y Random Forest ya superan el benchmark ($p<0,001$), mientras KNN no supera a la regresión lineal.

Brecha y KPI: la brecha se define como log(precio real) − log(precio esperado), haciendo simétricos los casos de mitad y doble de precio. El umbral preliminar corresponde a dos veces el error porcentual mediano: >53,0% por encima o >34,6% por debajo del esperado (log=0,425), fijado antes de la evaluación final. Con él, 20,5% de las publicaciones presenta desvío (9,8% por debajo; 10,7% por encima). Como deriva de los residuos, el KPI depende parcialmente de su dispersión y se utilizará para comparar segmentos y validar su relación con la demanda.

Cruce con demanda: se comparan las reseñas de los últimos doce meses entre el decil más subvaluado y el más sobrevaluado (Mann-Whitney unilateral) y la correlación de Spearman, con number_of_reviews_ltm por ser la única medida de reseñas independiente de la antigüedad (correlación de -0,02, contra 0,53 del total histórico). El resultado preliminar apoya la hipótesis (Spearman -0,159, $p < 0,001$) y se sostiene sin publicaciones sin reseñas o con menos de un año (-0,161 y -0,171).

Riesgos y próximos pasos: el residuo combina desvío de precio con calidad no observada: el decil más por debajo del esperado presenta menos actividad que el segundo (mediana 5 vs. 10 reseñas), por lo que se analizará la calificación. Próximos pasos: ajuste de hiperparámetros, sensibilidad de bedrooms, evaluación final sobre holdout y devolución del tutor. Entorno: Python 3.14, pandas 3.0, scikit-learn 1.9 y semilla fija.

Fuentes

Inside Airbnb. (2026). Buenos Aires, Argentina, snapshot del 29 de junio de 2026 [Conjunto de datos]. Licencia CC BY 4.0. https://insideairbnb.com/get-the-data/

scikit-learn. Statistical comparison of models using grid search. Ejemplos de la documentación, versión 1.9. https://scikit-learn.org/stable/auto_examples/model_selection/plot_grid_search_stats.html

Nadeau, C. y Bengio, Y. (2003). Inference for the generalization error. Machine Learning, 52, 239-281. https://doi.org/10.1023/A:1024068626366